

ÉVALUATION DES DISTANCES DE TRANSPORT OPTIMAL POW ET GOW POUR LA MODÉLISATION DE LA PERCEPTION PHONÉTIQUE HUMAINE

Léandre Raeth

Master 1 IAAA, Université d'Aix-Marseille

RESUMÉ

Ce travail, conduit dans le cadre du Master 1 IAAA à l'Université d'Aix-Marseille, évalue la capacité de métriques d'alignement temporel récentes, Partial Ordered Wasserstein (POW) [1] et Generalized Ordered Wasserstein (GOW) [2], à simuler le comportement humain lors d'une tâche de discrimination phonétique (ABX). À partir du corpus multilingue ZeroSpeech 2017 [4], le signal est modélisé via des MFCC [5] à 39 dimensions. Nous exploitons Perceptimatic [3], un dataset comportemental de 17 121 évaluations ABX par des auditeurs natifs anglophones et francophones, pour confronter nos modèles à la réalité perceptive.

Les résultats montrent que POW et GOW surpassent DTW sur les métriques cognitives (tables de contingence par Odds Ratio et corrélations modèle-humain par triplet).

Le code est disponible à : <https://github.com/RL-I3A/pow-gow-perceptimatic-2026.git>

Mots clés— Modèles, Distances temporelles, Partial Ordered Wasserstein (POW), Generalized Ordered Wasserstein (GOW), Dynamic Time Warping (DTW), MFCC, Parole, Tests ABX, Corrélations.

1. INTRODUCTION

La perception de la parole repose sur la capacité du système auditif à catégoriser des signaux acoustiques continus, bruités et variables en unités linguistiques distinctes [9]. Ce processus perceptif, largement automatique, opère sur une grande diversité de locuteurs, de contextes et de conditions d'enregistrement.

Les systèmes de traitement automatique de la parole atteignent aujourd'hui de bonnes performances en transcription, mais leurs représentations internes ne correspondent pas nécessairement à l'espace perceptif humain : deux sons jugés similaires par un auditeur ne le sont pas toujours selon une métrique automatique, et vice versa.

Modéliser cet espace perceptif, c'est-à-dire mesurer une dissimilarité entre séquences parlées qui rende compte des contrastes phonétiques difficiles ou faciles à discriminer pour un auditeur humain, constitue un objectif distinct de la transcription.

Pour comparer deux segments de parole représentés par des séquences de vecteurs acoustiques de longueurs variables, l'algorithme Dynamic Time Warping (DTW) [6] s'est imposé comme méthode de référence. DTW calcule l'alignement

optimal entre deux séquences en autorisant des correspondances non-linéaires entre trames, mais en imposant que l'intégralité du signal soit alignée. Cette contrainte peut rendre la métrique sensible à certains artefacts d'enregistrement ou à des différences de durée aux frontières des segments.

Notons que ces vulnérabilités concernent ici le DTW classique, et non ses variantes conçues pour mieux accommoder les outliers (par exemple Drop-DTW [7]). Plus précisément, le chemin d'alignement de DTW est contraint à la continuité (pas de saut entre trames consécutives) et à la monotonie (l'ordre temporel des deux séquences doit être préservé), ce qui interdit toute correspondance qui s'écarterait, même localement, de cet ordre strict.

C'est dans ce cadre que s'inscrit ce travail : évaluer deux distances issues de la théorie du Transport Optimal [8], POW [1] et GOW [2], comme alternatives à DTW pour modéliser la discrimination phonétique humaine. POW relâche la contrainte d'alignement exhaustif en n'alignant qu'une fraction de la masse du signal.

GOW permet de sélectionner une fonction de mise en correspondance entre séquences qui soit non-linéaire, ce qui permet par exemple d'aligner correctement deux séquences correspondant au même phénomène, mais réalisées à deux vitesses différentes. Notre problématique est : dans quelle mesure ces distances permettent-elles de prédire plus fidèlement le comportement perceptif humain que DTW ?

Ce rapport s'articule comme suit : la section 2 détaille le corpus Perceptimatic, la section 3 la méthodologie (extraction MFCC, hyperparamètres, implémentations), la section 4 les métriques et résultats, et la section 5 une discussion critique avec perspectives.

2. DONNÉES : PERCEPTIMATIC

2.1. Le protocole expérimental ABX

Le projet Perceptimatic [3] fournit un ensemble de données d'évaluations comportementales standardisées issues de flux de parole naturelle du corpus Zero Resource Speech Challenge 2017 [4].

L'expérience repose sur le paradigme ABX : un participant écoute trois extraits audio (A, B et X), formant un *triplet ABX*, de durées variables, et doit déterminer si la cible X correspond à la catégorie phonétique de A ou de B. Afin de garantir que l'évaluation porte sur la phonétique et non sur les caractéristiques individuelles du locuteur, X est systématiquement prononcé par un interlocuteur différent de A et B (*across speaker*).

Seul le phonème central varie entre A et B, dans un contexte phonétique strictement identique (phonème précédent et suivant). Les réponses sont collectées sur une échelle continue de -3 (A avec certitude) à $+3$ (B avec certitude), 0 exclu, puis binarisées pour les analyses.

À titre d'exemple, les données françaises présentent le contraste *prev.phone* = *i* (phonème précédent), *TGT* = *t* (phonème cible, ici celui de A), *OTH* = *p* (phonème alternatif, celui de B) et *next.phone* = ε (phonème suivant) : le participant discrimine [t] de [p] dans des parties de mots comme *cap[itai]ne* et *h[ype]r*.

2.2. Architecture du jeu de données

Le corpus s'appuie sur 184 participants natifs (93 francophones, 91 anglophones), dont seules les évaluations intra-langue (fr/fr et en/en) sont retenues. Cela représente 17 121 réponses individuelles portant sur 5 202 triplets distincts (3,29 évaluations par triplet en moyenne), répartis sur 461 contrastes de phonème central, 201 contextes phonétiques et 33 locuteurs (15 anglophones, 18 francophones). Aucun participant n'évalue deux fois la même paire de phonèmes, la combinaison de locuteurs ne prédit pas la bonne réponse, et aucun participant ne présente un taux de réussite inférieur à 55%.

Les données sont organisées en deux composantes principales : les évaluations comportementales associant à chaque essai le contraste testé et la réponse humaine, et les timestamps *onset/offset* permettant le découpage des segments audio¹.

3. MÉTHODOLOGIE ET DISTANCES D'ALIGNEMENT

3.1. Représentation acoustique : MFCC

Les coefficients MFCC (Mel Frequency Cepstral Coefficients [5]) constituent une représentation compacte du spectre acoustique à court terme, conçue pour capturer les caractéristiques spectrales du signal de parole tout en réduisant la redondance. Le calcul repose sur une banque de filtres à l'échelle de Mel, approximation de la résolution fréquentielle de l'oreille humaine, suivie d'une transformée en cosinus discrète. L'ajout des dérivées première (delta) et seconde (delta-delta) permet de caractériser la dynamique temporelle, portant la dimensionnalité à 39 coefficients par trame. Nous avons reproduit à l'identique le pipeline d'extraction du dépôt de référence², ce que confirme une corrélation de Pearson $r = 0,999$ entre nos deltas DTW et les DTW de référence du dataset.

La distance entre deux séquences est calculée par DTW et normalisée par la longueur maximale [3] :

$$d(C, D) = \frac{\sum_{c_i, d_j \text{ alignés}} \gamma(c_i, d_j)}{\max(p, q)} \quad (1)$$

où γ est la distance cosinus entre vecteurs MFCC, c_i et d_j les trames respectives des séquences C et D , et p et q les longueurs des deux séquences.

3.2. Présentation des distances

Pour les deux distances POW et GOW comme pour DTW, nous utilisons comme *ground metric* la distance cosinus entre vecteurs MFCC, par souci de comparabilité directe avec la distance DTW de référence (équation 1). Pour les paramètres intrinsèques à chaque méthode, nous reprenons les valeurs par défaut suggérées dans les papiers originaux et leurs implémentations de référence [1, 2, 15, 14] (le détail exhaustif des paramètres est disponible dans notre dépôt Github²). Concernant la proportion de masse transportée pour POW, et compte tenu du fait que la proportion d'outliers est réputée faible dans notre contexte applicatif, nous avons choisi de ne pas utiliser l'algorithme d'estimation dynamique suggéré dans le papier, mais de fixer cette proportion à une valeur globale de 95%.

3.3. Implémentations des distances

3.3.1. GOW : Generalized Ordered Wasserstein

L'idée fondamentale du Transport Optimal est de trouver le plan de transport π minimisant le coût moyen de déplacement de masse entre deux distributions, ici les distributions de trames acoustiques de deux séquences [8]. Appliqué aux séries temporelles, GOW enrichit ce cadre en ajoutant une pénalité structurelle guidée par des fonctions temporelles *a priori* [2]. Contrairement au DTW qui impose une contrainte d'alignement absolument monotone et rigide, GOW permet une plus grande flexibilité en appliquant une pénalité souple (*soft penalty*) aux correspondances qui s'éloignent de l'ordre temporel modélisé [2].

L'optimisation de GOW est un problème conjoint consistant à trouver simultanément le plan de transport π et la combinaison optimale des poids w définissant la déformation temporelle. Pour ce faire, le modèle s'appuie sur deux algorithmes imbriqués [2] :

- **L'algorithme de Frank-Wolfe** : Il constitue la boucle d'optimisation principale. Il met à jour les poids w par descente de gradient à pas contraints sur le simplexe, garantissant que la combinaison des fonctions reste valide sans sortir du domaine admissible.
- **L'algorithme de Sinkhorn** : À chaque itération de Frank-Wolfe, le calcul exact du plan de transport π étant trop coûteux, une version régularisée est résolue. L'ajout d'un terme entropique $\lambda_2 H(\pi)$ rend le sous-problème strictement convexe, permettant un calcul ultra-rapide par multiplications matricielles itérées.

Le paramètre λ_1 contrôle l'importance accordée à cette pénalité temporelle face au coût acoustique pur.

La matrice de coût entre les trames de deux séquences est construite via la distance cosinus entre vecteurs MFCC, normalisée dans $[0, 1]$. La déformation temporelle de GOW

¹Données disponibles, en complément de [3], à : [10] <https://github.com/JAMJU/interspeech-2020-perceptimatic>

²Pipeline Kaldi [11] disponible à notre dépôt [13] : <https://github.com/RL-I3A/pow-gow-perceptimatic-2026.git>

repose sur $K = 25$ fonctions de base (exponentielles, logarithmiques, tangentes hyperboliques, polynomiales et I-splines) [2]. Les paramètres intrinsèques de ces courbes n'étant pas publiés, nous les avons reconstruits par rétro-ingénierie : numérisation des figures via Plot Digitizer [12] et ajustement par régression non-linéaire (moindres carrés), détaillé dans `courbes.ipynb`².





Fig. 1. Les 25 fonctions de base reconstruites par rétro-ingénierie [2].

Hyperparamètres. Nous utilisons $\lambda_1 = 5$ (dans la plage de stabilité [1, 100] identifiée par [2]) et $\lambda_2 = 10$ (valeur par défaut du dépôt², non réoptimisée).



4.2. Résultats

4.2.1. Fidélité du pipeline et corrélations inter-modèles

Notre DTW présente une corrélation de Pearson $r = 0,999$ avec le DTW de référence du dataset, ce qui valide la quasi-parfaite fidélité de notre pipeline d'extraction par rapport au dépôt de référence. La figure 3 présente les nuages de points des deltas entre chaque paire de modèles. POW et DTW ($r = 0,920$) : forte corrélation attendue (objectif d'alignement temporel partagé, malgré des cadres théoriques distincts), mais la dispersion confirme que POW introduit une géométrie distincte. GOW présente les corrélations les plus faibles : $r = 0,842$ avec DTW et $r = 0,912$ avec POW, confirmant que les déformations non-linéaires réorganisent substantiellement l'espace de décision. La corrélation GOW-POW plus élevée que GOW-DTW s'explique par leur cadre théorique commun (Transport Optimal).




Fig. 3. Nuages de points des deltas entre chaque paire de modèles (Notre DTW, POW, GOW, DTW de référence).

4.2.2. Plafond humain vs. humain

Par essai expérimental (référence pour les tables de contingence) : $r = 0,24 \pm 0,008$. Les deux demi-groupes s'accordent dans 75,5% des cas (69,9% de réussites communes, 5,6% d'erreurs communes), avec 12,2–12,3% de désaccords. L'Odds Ratio vaut $OR = 2,61$: lorsqu'un groupe se trompe, l'autre a 2,61 fois plus de chances de se tromper également, preuve que l'erreur est structurée par l'ambiguïté acoustique. Cet OR constitue le plafond de référence.

Par triplet (référence pour les corrélations) : en agrégeant par type linguistique de stimulus (en moyenne 3,29 essais par type), la variabilité individuelle se lisse et la corrélation monte à $r = 0,41 \pm 0,013$, soit la limite supérieure atteignable sur ce corpus.

4.2.3. Tables de contingence

La figure 4 présente les tables de contingence humain vs. modèle pour chaque langue.

Accuracy brute. Les humains atteignent 79,5% en anglais et 84,1% en français. Les modèles sont comparables entre eux : en anglais, DTW 78,9%, POW 78,1%, GOW 75,4% ; en français, DTW 78,1%, POW 79,6%, GOW 76,7%.

Structure de l'erreur, corpus anglophone. DTW ($OR = 1,86$, $p = 0,364$) : les désaccords avec les humains

ne sont pas statistiquement structurés. POW ($OR = 2,00$, $p < 0,05$) et GOW ($OR = 2,08$, $p < 0,001$) améliorent significativement ce résultat, GOW atteignant $\approx 80\%$ du plafond humain (2,61).

Structure de l'erreur, corpus francophone. La hiérarchie est identique, avec une significativité très forte pour tous les modèles : DTW ($OR = 1,72$, $p < 0,001$), POW ($OR = 1,97$, $p < 0,001$), GOW ($OR = 1,94$, $p < 0,001$). Les OR inférieurs à ceux de l'anglais s'expliquent par la plus grande diversité des contrastes français (249 contre 212), rendant la tâche structurellement plus variable.

DTW, contraint par son alignement exhaustif, capture la structure de l'erreur humaine de façon non significative en anglais. POW et GOW, en relâchant ces contraintes, la reproduisent significativement mieux dans les deux langues.

Matrice de confusion – Humain vs Modèle (par ligne)

GOW – ENGLISH (n=842)		DTW FRENCH – ENGLISH (n=842)		POW – ENGLISH (n=842)		Humain vs Humain – ENGLISH (n=3408)	
Humain correct 79.5%	21.5% (n=137)	81.2% (n=683)	18.8% (n=159)	80.8% (n=683)	19.2% (n=159)	81.8% (n=223)	18.2% (n=53)
Humain erreur 20.5%	62.2% (n=488)	69.8% (n=583)	30.2% (n=259)	67.8% (n=563)	32.2% (n=259)	66.4% (n=193)	33.6% (n=97)
Modèle correct 78.9%	21.1% (n=169)	79.5% (n=663)	20.5% (n=179)	81.5% (n=683)	18.5% (n=159)	81.8% (n=223)	18.2% (n=53)
Modèle erreur 21.1%	78.9% (n=622)	69.8% (n=583)	30.2% (n=259)	67.8% (n=563)	32.2% (n=259)	66.4% (n=193)	33.6% (n=97)
Humain correct 84.1%	15.9% (n=125)	79.5% (n=663)	20.5% (n=179)	81.5% (n=683)	18.5% (n=159)	81.8% (n=223)	18.2% (n=53)
Humain erreur 15.9%	84.1% (n=657)	69.8% (n=583)	30.2% (n=259)	67.8% (n=563)	32.2% (n=259)	66.4% (n=193)	33.6% (n=97)
Modèle correct 76.7%	23.3% (n=184)	79.5% (n=663)	20.5% (n=179)	81.5% (n=683)	18.5% (n=159)	81.8% (n=223)	18.2% (n=53)
Modèle erreur 23.3%	76.7% (n=604)	69.8% (n=583)	30.2% (n=259)	67.8% (n=563)	32.2% (n=259)	66.4% (n=193)	33.6% (n=97)

Fig. 4. Tables de contingence humain vs. modèle par langue (Notre DTW, POW, GOW et plafond humain vs. humain).

4.2.4. Corrélations humain-machine par triplet

Plafond de référence : $r = 0,41 \pm 0,013$.

Corrélation modèle-humain (Figure 5). Toutes les corrélations sont hautement significatives ($p < 10^{-23}$). En français : POW $r = 0,288$, GOW $r = 0,264$, DTW $r = 0,261$. En anglais : POW $r = 0,333$, GOW $r = 0,314$, DTW $r = 0,292$ (64 à 81% du plafond).

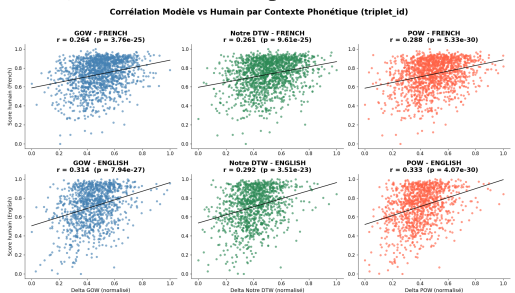


Fig. 5. Corrélations modèle-humain par triplet (contexte phonétique global).

Types de triplets réussis par les humains (Figure 6). Les corrélations baissent mais restent significatives. En français : DTW $r = 0,230$, POW $r = 0,225$, GOW $r = 0,219$. En anglais : POW $r = 0,213$, GOW $r = 0,211$, DTW $r = 0,183$.

Types de triplets ratés par les humains (Figure 7). Les corrélations s'effondrent et deviennent non significatives en français (GOW $r = -0,019$, $p = 0,615$; DTW $r = 0,005$, $p = 0,889$; POW $r = 0,021$, $p = 0,549$), et en anglais ($r \approx 0,07$). Sur ces zones d'ambiguïté, aucun modèle ne dispose de signal acoustique suffisant pour ordonner la difficulté : le delta fluctue aléatoirement, comme un auditeur face à un contraste indiscernable.

La corrélation continue est portée presque exclusivement




Fig. 6. Corrélation modèle-humain sur les types de triplets réussis par les humains




Fig. 7. Corrélation modèle-humain sur les types de triplets ratés par les humains. POW présente l'avantage le plus consistant dans les deux langues pour cette métrique, suggérant que le filtrage des outliers acoustiques aligne mieux la certitude du modèle sur la difficulté perçue.

5. DISCUSSION ET PERSPECTIVES

5.1. Synthèse

Sur l'accuracy brute (75–80%), les trois modèles sont comparables, validant la viabilité des implémentations. Les différences s'affirment sur les métriques cognitives : les tables de contingence montrent que DTW reproduit la structure de l'erreur humaine de façon non significative en anglais, tandis que POW et GOW l'améliorent significativement (OR jusqu'à 2,08, soit 80% du plafond de 2,61). Les corrélations continues par triplet confirment cet avantage, POW présentant les meilleures valeurs dans les deux langues ($r = 0,288$ en français, $r = 0,333$ en anglais).

Ces deux métriques sondent des aspects complémentaires de l'accord humain-machine. Les tables de contingence évaluent si le modèle commet les mêmes erreurs discrètes que les humains essai par essai (GOW légèrement meilleur en anglais, OR 2,08 vs 2,00). La corrélation continue mesure si le delta du modèle reflète la certitude graduée des auditeurs au niveau des types de triplets (POW systématiquement meilleur). Cette dissociation est cohérente avec la nature de POW : en filtrant les portions les moins fiables du signal ($s = 0,95$), POW produit des deltas plus proches du niveau de performance brute humain, ce qui se traduit par une meilleure prédiction de la difficulté graduée. GOW, dont la déformation non-linéaire apprend à distinguer les contrastes difficiles des faciles, capture mieux la binarisation de l'erreur. Les deux approches sont donc complémentaires plutôt que concurrentes.

5.2. Limites

Les corrélations, bien que hautement significatives, demeurent modestes ($r \approx 0,26$ – $0,33$). Cet écart par rapport au plafond ($r = 0,41$) reflète en partie les différences interindividuelles entre participants, le plafond humain vs. humain intègre déjà cette variabilité et représente donc la limite atteignable sur ce corpus, non une cible absolue. Une autre part de l'écart découle de la représentation MFCC, modélisation de bas niveau surpassée par les représentations latentes profondes multilingues [3].

Par ailleurs, les stimuli sont courts (237 ms en moyenne) et ont été manuellement nettoyés et réalignés [3], minimisant précisément les artefacts que GOW et POW sont théoriquement conçus pour gérer. Leurs avantages sont donc structurellement sous-exploités dans ce corpus.

5.3. Perspectives

La direction prioritaire est la substitution des MFCC par des embeddings issus de modèles profonds multilingues (type S2 de Perceptimatic), afin de déterminer si POW et GOW apportent un gain similaire sur des représentations de plus haut niveau, et notamment si l'on peut saturer le plafond perceptif référence humaine. Il serait également pertinent de les évaluer sur des séquences plus longues et non pré-segmentées, où les distorsions temporelles et outliers acoustiques sont réellement présents.

Références

6. REFERENCES

- [1] T. Doan, T. Phan, P. Nguyen, K. Than, M. Visani, A. Takasu, “Partial Ordered Wasserstein Distance for Sequential Data,” *Neurocomputing*, 2024.
- [2] T. Doan, H. To, H. Vuong, M. Visani, A. Takasu, K. Than, “Generalized Ordered Wasserstein Distance,” *Pattern Recognition*, 2025.
- [3] J. Millet, E. Dunbar, “Perceptimatic: A Human Speech Perception Benchmark for Unsupervised Subword Modelling,” *Proc. Interspeech*, 2020.
- [4] E. Dunbar, X. N. Cao, J. Benjumea, J. Karadayi, M. Bernard, L. Besacier, X. Anguera, E. Dupoux, “The Zero Resource Speech Challenge 2017,” in *Proc. IEEE Workshop on Automatic Speech Recognition and Understanding (ASRU)*, IEEE, 2017, pp. 323–330.
- [5] S. B. Davis, P. Mermelstein, “Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences,” *IEEE Trans. Acoust. Speech Signal Process.*, vol. 28, no. 4, pp. 357–366, 1980.
- [6] H. Sakoe, S. Chiba, “Dynamic Programming Algorithm Optimization for Spoken Word Recognition,” *IEEE Trans. Acoust. Speech Signal Process.*, vol. 26, no. 1, pp. 43–49, 1978.
- [7] N. Dvornik, I. Hadji, K. G. Derpanis, A. Garg, A. D. Jepson, “Drop-DTW: Aligning Common Signal Between Sequences While Dropping Outliers,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [8] C. Villani, *Topics in Optimal Transportation*, Graduate Studies in Mathematics, vol. 58, American Mathematical Society, Providence, RI, 2003.
- [9] International Phonetic Association, *Handbook of the International Phonetic Association: A Guide to the Use of the International Phonetic Alphabet*, Cambridge University Press, Cambridge, 1999.
- [10] J. Millet, E. Dunbar, “Perceptimatic – Source code repository,” GitHub, 2020. <https://github.com/JAMJU/interspeech-2020-perceptimatic>
- [11] D. Povey, A. Ghoshal, G. Boulianne, L. Burget, O. Glembek, N. Goel, M. Hannemann, P. Motlicek, Y. Qian, P. Schwarz, J. Silovsky, G. Stemmer, K. Vesely, “The Kaldi Speech Recognition Toolkit,” in *Proc. IEEE Workshop on Automatic Speech Recognition and Understanding (ASRU)*, IEEE Signal Processing Society, 2011.
- [12] Plot Digitizer. <https://plotdigitizer.com>
- [13] <https://github.com/RL-I3A/pow-gow-perceptimatic-2026.git>
- [14] H. To, T. Doan, “Generalized Ordered Wasserstein – Source code repository,” GitHub, 2025. <https://github.com/TungDP/GOW>
- [15] T. Doan, “Partial Ordered Wasserstein Distance – Source code repository,” GitHub, 2024. <https://github.com/TungDP/Partial-Ordered-Wasserstein-Distance>
- [16] J. M. Bland, D. G. Altman, “Statistics Notes: The Odds Ratio,” *BMJ*, vol. 320, no. 7247, p. 1468, 2000.
- [17] Q. McNemar, “Note on the Sampling Error of the Difference between Correlated Proportions or Percentages,” *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947. <https://doi.org/10.1007/BF02295996>